

C-index 연구 관련 보고사항

경희대학교 컴퓨터공학과 강병오

1) 개선사항 요약

새로운 feature를 추가하기 전에, 교수님이 지적하신 **재현성 문제(seed)**와 **성과평가 지표의 계산 신뢰성(Sharpe/MDD)**을 먼저 정리하는 것을 목표로 두었습니다.

결론적으로, 코드 수준에서 핵심 문제였던 seed 고정과 Sharpe 폭발 문제를 대부분 해결했고, 특히 기존 Best Scenario에서 관찰되던 Sharpe: 36.69와 같은 비현실적 수치는 성과가 좋아서가 아니라 **강한 필터링 이후 거래 수가 2~5건으로 줄어드는 소표본 편향** 때문임을 확인했고, 이를 막기 위해 여러 방식을 도입했습니다.

다만 실행 결과를 해석하면, 현재 실험은 C-index 가설을 강하게 입증한다기보다는 **부분적으로만 지지**하는 것 같습니다. 설명 불일치 자체가 가 높다는 사실은 교수님의 말씀대로 고무적이기도 하고, 재현성을 확보한 이후에도 재확인되었지만, 그 불일치를 이용한 거래 필터링이 모든 모델과 자산에서 일관되게 수익·리스크를 개선한다고 보기에는 아직 표본 수와 통계 검정이 부족하다고 느껴집니다. 표본 수를 oep window의 step을 10에서 2로 확 줄이니까 뭔가 전체적으로 설명력이 올라간 느낌이 드는데, 제 느낌일지 아니면 실제로 개선된 것 같은지 교수님의 의견 여쭙고 싶습니다.

추가적으로 이번 실험을 진행하면서 여러 개를 한번에 수정하다보니 원인 파악이 안되어서 처음부터 다시 시작하는 등의 어려사항이 많이 발생해서, 지금부터는 binary하게 하나 하나 해결해보고 싶은데, 다음 step으로 feature 설계로 모델 자체의 성능을 올리는 방향으로 갈지 (강한 학습기를 쓰면 뭔가 성능향상 폭도 늘어나지 않을까 하는 생각이 들기도 합니다) 아니면 다른 쪽 보완이 시급한 지 궁금합니다.

2) 항목별 개선사항

2-1) Seed 일괄 고정

- 작업 내용

노트북 상단 Cell 2에 전역 seed 고정 함수 추가

GLOBAL_SEED = 42

```
def set_global_seed(seed=GLOBAL_SEED):  
    os.environ['PYTHONHASHSEED'] = str(seed)  
    random.seed(seed)  
    np.random.seed(seed)  
    torch.manual_seed(seed)  
    torch.cuda.manual_seed_all(seed)  
    torch.backends.cudnn.deterministic = True  
    torch.backends.cudnn.benchmark = False
```

set_global_seed()

- 작업 위치

구성 요소	적용 내용
Global seed	random, numpy, torch, CUDA/cuDNN deterministic 설정
LightGBM	seed=42 명시

구성 요소	적용 내용
RandomForest	random_state=42 명시
MLP	torch.manual_seed(42) 및 DataLoader(generator=...) 적용
SHAP / Permutation	set_global_seed(SEED), seed=SEED, np.random.default_rng(seed) 적용
train/valid split	시점 기준 80/20 split이므로 무작위 분할 없음

- 현재 판단

코드 구조상 재현성 확보를 위한 seed 고정은 완료되었고, 수정 후 동일 데이터 캐시 조건에서 3회 반복 실행 결과 핵심 출력이 완전히 일치함을 확인했습니다.

2-2) Sharpe 비정상 수치 문제

- 원인 진단

MLP Sharpe 36.69, GBM Sharpe 10.69 같은 값은 현실적으로 말이 되지 않으므로 annualize 오류, look-ahead bias, 거래비용 미반영, 표본 부족을 점검해야 한다고 말씀을 해주셨습니다. 그래서 검토를 진행을 해보았고, 핵심 원인은 **소표본으로 인한 문제였습니다**. quantile을 설정하여 거래를 집행하는 방식이었기 때문에, q=0.4~0.5처럼 강한 필터링을 적용하면 거래 수가 2~5건으로 줄어들었고, 이때 수익률 표준편차가 0에 가까워지면서 Sharpe ratio가 수학적으로 폭발했고, 이후 단순히 Sharpe 기준으로 내림차순 정렬하면서 이 값들이 Best Scenario로 선택되었던 것으로 파악하였습니다.

- 코드 수정

compute_metrics()를 다음 방향으로 수정했습니다

수정 항목	내용
최소 거래 수 기준	pooled 분석은 MIN_TRADES_POOLED = 15
자산별 기준	asset-wise 분석은 MIN_TRADES_ASSET = 5, 단 Sharpe 해석은 보조 지표로 전환
Sharpe 안전장치	분모에 epsilon = 1e-6 추가
소표본 처리	$n < \text{min_trades}$ 이면 Sharpe = NaN, Sharpe_annualized = NaN, Note에 소표본 경고
Best Scenario 선정	pooled best_rows 추출 전 Trade Count ≥ 15 선행 필터

또한 기존에는 자산별 분석에서도 Sharpe 최고값을 best로 뽑았으나, 개별 자산 단위에서는 표본이 1/3으로 나눠짐에 따라서 본질적으로 작기 때문에 win rate이라는 개념을 도입하여서, bestAssetRows 기준을 **Sharpe가 아니라 Win Rate 개선 중심**으로 바꾸었습니다.

- 해결 여부

Sharpe 폭발 문제는 해결되었고, 실행 결과에서 pooled Best Scenario는 모두 $N \geq 15$ 조건을 만족하며, 기존처럼 거래 2~5건짜리 시나리오가 Best로 뽑히지 않았습니다.

다만 MLP pooled best의 Sharpe_annualized는 5.8739로 여전히 5를 넘는데, 이는 오류라기보다는 Trade Count = 15로 최소 기준을 간신히 넘은 상태에서 나온 결과로 해석됩니다. 따라서 본문에서는 annualized Sharpe를 주 지표로 쓰기보다 **per-trade Sharpe와 Trade Count를 함께 제시**하는 것이 어떨까 싶습니다.

2-3) Disagreement rate 재현성 확인

- 실행 결과

수정 후 실행 결과에서도 설명 불일치는 높게 유지되었습니다 (확정값)

Model	Disagree@1	Disagree@3	Disagree@5	Disagree@10
GBM	0.8793	0.8621	0.7241	0.1207
MLP	0.7586	0.7586	0.6379	0.0345
RF	0.9310	0.8793	0.7414	0.1034

2-4) MDD improved 가 0이었던 문제

Robustness 표에서 세 모델 모두 MDD_Improved = 0으로 나오는 것은 이상하다고 말씀해주셔서, 집계 로직 오류를 발견하였고, 이를 개선하였습니다.

- 작업 내용

우선, MDD에 대한 판단을 다음과 같이 설정을 하였습니다.

MDD_Improved = (Delta MDD > 0)

MDD_Equal = (Delta MDD == 0)

MDD_Worsened = (Delta MDD < 0)

아래는 이후, 실행 결과입니다.

Model	WinRate_Improved	AvgReturn_Improved	MDD_Improved	MDD_Equal	MDD_Worsened
GBM	3	3	1	2	0
MLP	2	2	2	1	0
RF	3	2	3	0	0

3) 실험결과 (Pooled)

- No Filter baseline

Model	Trade Count	Avg Return	Win Rate	Sharpe	Sharpe_annualized	MDD
GBM	16	0.2105	56.25	0.1839	2.9193	-3.1166
MLP	25	0.3232	64.00	0.2297	3.6464	-6.3981
RF	37	0.0807	56.76	0.0501	0.7958	-10.0922

- C-index filtered best (단 trade count >= 15 통과 시나리오만)

Model	Best C-index	q	Trade Count	Avg Return	Win Rate	Sharpe	Sharpe_annualized	MDD
GBM	C_tau_full	0.2	16	0.2105	56.25	0.1839	2.9193	-3.1166
MLP	C_tau_ties10	0.4	15	0.5456	73.33	0.3700	5.8739	-3.1597
RF	C_tau_f	0.5	24	0.1865	54.17	0.1457	2.3135	-4.4708

Model	Best C-index	q	Trade Count	Avg Return	Win Rate	Sharpe	Sharpe_anualized	MDD
-------	--------------	---	-------------	------------	----------	--------	------------------	-----

- 모델별 해석

- GBM은 필터링 후 best가 baseline과 사실상 동일했고, 현재 조건에서는 C-index 필터가 GBM 신호를 실질적으로 개선했다고 보기 어려웠습니다.

- MLP는 Avg Return, Win Rate, Sharpe, MDD가 모두 개선되었습니다. 다만 Trade Count가 25건에서 15건으로 줄었고 annualized Sharpe가 5.8739로 높기 때문에, 필터링 후 유리한 거래만 남았을 가능성이 있긴 합니다.

- RF는 가장 안정적인 개선 패턴을 보여줍니다. Trade Count가 37건에서 24건으로 줄었지만 Sharpe와 MDD가 함께 개선되었습니다. 다만 Win Rate는 56.76에서 54.17로 낮아졌으므로, 개선은 승률보다는 평균수익과 drawdown 완화 중심으로 이루어진 것으로 확인됩니다.

결론적으로 이 결과로만 봐선 pooled 결과는 **MLP와 RF에서 부분적 개선, GBM에서는 개선 없음**으로 정리하는 것이 타당하다고 판단됩니다.

4) 실험결과 (자산별)

앞서 말씀드린 것처럼 자산별 best는 Sharpe가 아니라 Win Rate 기준으로 선정했습니다. 이는 자산별 거래 수가 작아 Sharpe를 신뢰하기 어렵다고 판단했기 때문입니다.

Model	Asset	Best C-index	q	Trade Count	Win Rate	Avg Return	Delta Win Rate	Delta Avg Return	Delta MDD
GBM	GLD	C_RBO_full	0.2	1	100.00	1.5367	+50.0000	+1.1398	0.0000
GBM	SPY	C_RBO_full	0.5	5	80.00	0.8850	+10.0000	+0.5130	+2.2733
GBM	TLT	C_Mallows_full	0.5	3	33.33	-0.2274	+8.3333	+0.0591	0.0000
MLP	GLD	C_Mallows_full	0.2	6	100.00	1.4229	0.0000	0.0000	0.0000
MLP	SPY	C_RBO_full	0.5	4	100.00	1.0586	+25.0000	+0.5994	+3.1597
MLP	TLT	C_Mallows_full	0.5	2	50.00	-0.3509	+35.7143	+0.5015	+4.8012
RF	GLD	C_tau_ties3	0.4	7	85.71	1.0137	+5.7143	+0.0545	+0.3068
RF	SPY	C_tau_ties10	0.5	9	77.78	-0.0857	+11.1111	-0.0159	+1.3599
RF	TLT	C_tau_ties3	0.5	8	37.50	-0.2702	+12.5000	+0.1931	+3.3987

- 해석

자산별 결과만 보면 Win Rate와 MDD가 개선되는 사례가 많았고, 특히 RF는 GLD, SPY, TLT 세 자산 모두에서 Win Rate와 MDD가 개선되었습니다. 다만 RF SPY는 Avg Return이 소폭 악화되어, 자산별 효과를 모든 지표에서 일관된 개선으로 말하기는 어렵습니다.

하지만 이 결과를 강하게 주장하기에는 두 가지 문제가 있다고 판단됩니다.

첫째로, pool에 비해서 상승은 명확하게 드러나는데, 반복되는 문제이긴 하지만 표본 수가 작아서 그럴 수 있다고 생각됩니다. GBM GLD는 거래 1건, MLP TLT는 거래 2건, GBM TLT는 거래 3건인데, 이 정도 표본에서는 승률 100%, MDD 0 같은 값이 쉽게 발생할 수 있을 것 같고, 표본을 늘린다고 하더라도 어쨌든 자산별로 나누게 되면 항상 데이터가 1/3이 되니까 개선 후에 최종 결론에서도 자산별 결과는 “방향성 확인” 정도로만 써야 하지 않나 하는 생각이 듭니다. 아니면 다른 통계적 검정 방법이 있는지 궁금합니다.

둘째, best scenario를 여러 C-index 변형과 여러 q 중에서 사후적으로 고른 구조이기 때문에, selection bias가 존재해서, 뭔가 전체적으로 성능을 올려서 q sweep 결과 또는 평균 개선률도 함께 보여주는 것이 좋을 것 같다고 생각이 들었습니다.

4) 가설 지지 여부에 대한 개인적인 판단

4-1) 문제 제기에 대한 부분

설명 기법 간 ranking 불일치가 높다는 부분은 지지되는 것 같습니다. Top-3 disagreement가 GBM 0.8621, MLP 0.7586, RF 0.8793으로 높게 나타났고, 이는 C-index라는 별도 reliability index를 도입할 필요성을 뒷받침하기 때문에, “예측 확률만으로는 모델 판단의 구조적 안정성을 볼 수 없다”는 연구 동기는 여전히 유효한 것 같습니다.

4-2) C-Index

C-index 필터링이 거래 성과를 개선한다는 가설은 부분적으로만 지지되는 것으로 확인됩니다.

MLP의 pooled 결과에서는 필터링 후 Avg Return, Win Rate, Sharpe, MDD가 개선되었고, RF는 Win Rate는 소폭 낮아졌지만 Avg Return, Sharpe, MDD가 개선되어 가장 설득력 있는 사례인 것 같습니다. 하지만 GBM은 pooled 기준에서 baseline과 best가 동일하며, 자산별 결과도 거래 수가 너무 적은 케이스가 포함되어 있어서. 따라서 현재 결과만으로 “C-index 필터링은 model-agnostic하게 일관된 성과 개선을 만든다”고 주장하는 것은 무리인 것 같습니다.

4-3) 부족한 부분 리스트 up

- C-index가 모든 모델에서 일관되게 성과를 개선한다
- C-index가 모든 자산군에서 범용적으로 작동한다
- C-index가 통계적으로 유의한 Sharpe 개선을 만든다
- C-index가 거래비용 반영 후에도 실무적으로 유효하다

추가적으로, “높은 disagreement가 실제 손실 구간과 직접 연결된다”도 검증 필요할 것 같습니다.

5) Step 축소를 통해 표본 늘린 후 추가 실험 진행

5-1) Step을 줄인 이유

기존에 랭킹 산출을 할 때 시간 문제 때문에, STEP=10 으로 진행을 하였는데, 실험의 가장 큰 한계는 OEP 기간이 약 2년으로 짧다는 점도 있었지만, 더 직접적인 병목은 rolling window를 10일 간격이어서 표본이 더 부족해졌다는 점이라고 판단했습니다.

근데, OEP 자체를 늘리면 학습/검증 구간 구조가 바뀌고, 시장 레짐도 함께 달라지기 때문에 실험 설계 전체가 흔들릴 수 있다고 생각해서. STEP을 줄이는 방식을 통해서 동일 OEP와 동일 모델을 유지하면서 C-index 관측 시점만 촘촘하게 늘리고자 했습니다.

5-2) 표본 수 변화

STEP을 10에서 2로 줄여서 ranking dataset 규모가 약 5배 증가시켰습니다.

항목	STEP=10	STEP=2
GLD windows/model	20	100
SPY windows/model	18	87
TLT windows/model	20	100
모델별 ranking rows	58	287
전체 ranking rows	174	861

5-3) Pooled 성과 변화

STEP=2에서는 pooled 기준 No Filter 거래 수와 Best Filter 거래 수가 모두 크게 늘었습니다

Model	STEP=10 No Filter Trade	STEP=2 No Filter Trade	STEP=10 Best Trade	STEP=2 Best Trade
GBM	16	67	16	32
MLP	25	116	15	66
RF	37	172	24	97

성과 측면에서도 STEP=2는 STEP=10보다 안정적인 패턴을 보였습니다.(성과 자체가 증가함)

Model	STEP=2 No Filter Sharpe	STEP=2 Best Sharpe	STEP=2 No Filter MDD	STEP=2 Best MDD
GBM	0.1854	0.3212	-7.2516	-2.9556
MLP	0.1381	0.2211	-9.4205	-7.2789
RF	0.1326	0.1906	-13.7280	-10.3337

앞서 STEP=10에서는 GBM의 pooled best가 baseline과 동일하여 필터링 효과가 없었지만, STEP=2에서는 GBM도 Sharpe와 MDD가 모두 개선되어서, MLP와 RF 역시 Sharpe 및 MDD 개선이 유지되었습니다. 따라서 기존 STEP=10에서 관찰된 불안정성 중 상당 부분은 C-index 아이디어 자체의 실패라기보다, STEP=10에서 발생한 관측 표본 부족 문제의 영향이 컸을 가능성이 있다고 생각하는데, 이게 과장된 해석인지 타당한지 궁금합니다.

5-4) Sharpe 폭발 문제 추가 완화

STEP=10에서는 MLP best의 Trade Count가 15로 최소 기준에 간신히 걸쳤고, annualized Sharpe도 5.8739로 높게 나타났었는데, STEP=2에서는 거래 수가 크게 늘면서 Sharpe 해석이 더 안정화되었습니다.

Model	STEP=2 Best Trade	Sharpe	Sharpe_annualized
GBM	32	0.3212	5.0982
MLP	66	0.2211	3.5106
RF	97	0.1906	3.0261

MLP와 RF의 annualized Sharpe는 3점대 수준으로 내려와 기존의 비정상적 폭발 문제에서 벗어났습니다. 다만 이번에는 GBM의 annualized Sharpe가 5.0982로 조금 과하게 높게 나오긴 했는데, trade count 자체가 늘기도 했고 해서, 소표본에 따른 Sharpe 왜곡을 상당히 완화하는 것으로 판단됩니다. annualize했을 때 수치 문제가 생기는 거 같기도 해서, 이부분의 코드를 뭔가 잘못짚나 검토해야 하나 싶은데, 교수님의 의견은 어떠신지 궁금합니다. (납득 가능한 수치 범위 내에 있는지 등)

5-5) 자산별 분석의 표본 안정성 개선

자산별 best scenario의 거래 수 역시 크게 증가하였습니다.

Model	Asset	STEP=10 Best Trade	STEP=2 Best Trade
GBM	GLD	1	6
GBM	SPY	5	18
GBM	TLT	3	15
MLP	GLD	6	21
MLP	SPY	4	27
MLP	TLT	2	15
RF	GLD	7	45
RF	SPY	9	36
RF	TLT	8	42

특히 MLP와 RF는 모든 자산에서 15건 이상의 best trade count를 확보하거나 이에 가까운 수준으로 증가하였습니다.

자산별 robustness는 아래와 같이 개선되었습니다.

Model	WinRate_Improved	AvgReturn_Improved	MDD_Improved
GBM	3/3	3/3	3/3
MLP	3/3	3/3	3/3
RF	2/3	2/3	2/3

이는 STEP=2에서 C-index 필터링의 방향성이 STEP=10보다 더 일관적으로 나타났음을 확인했습니다. GBM과 MLP는 자산별 best 기준으로 세 자산 모두에서 Win Rate, Avg Return, MDD가 개선되었고, RF도 3개 자산 중 2개에서 개선이 확인되었습니다.

6) 아직 남은 과제들

6-1) 통계 검정

Pooled best에 대해 bootstrap 또는 permutation test를 추가해야 하는 것으로 알고있는데, 제가 통계 쪽 베이스가 조금 부족해서, 이 부분에 대해서 교수님의 키워드를 던져주시면 해당 부분 학습 진행하면서 연구에 반영까지 해보겠습니다.

6-2) 거래비용 반영

일전에 말씀해주신 것처럼 거래비용 0bp, 5bp, 10bp를 반영해야 실무적 설득력이 생기기에 반영해야 할 것 같습니다. 이 부분은 상대적으로 빠르게 진행할 수 있을 것 같습니다.

6-3) 모델 예측 성능 (재현성은 확보됨)

Model	Valid AUC	Balanced Accuracy
GBM	0.5089	0.5289
RF	0.5216	0.5303
MLP	0.5364	0.5410

세 모델 모두 AUC가 0.51~0.54 수준으로, 즉, base model 자체의 예측력이 약합니다. 이는 C-index 필터링의 역할을 “강한 alpha 모델 위의 추가 개선”으로 설명하기 어렵게 만드는데, 교수님 말씀대로 오히려 현재 프레이밍은 **약한 모델임에도 불구하고 상대적으로 믿을 수 있는 구간을 선별하는 reliability filter**쪽으로 갈지(모델을 여러 개 쓴 앙상블이 아니라 모델

하나에 설명기법을 여러개 쓴 앙상블 느낌), 아니면 실무에서 약한 모델로 트레이딩을 할 일이 없으니 강한 모델의 성능을 끌어올리는 쪽으로 가야할 지 모르겠습니다. 아니면, 강한 모델에도 적용하고 약한 모델 에도 적용해서 가야하는 것이 좋을 지도 아직은 판단이 잘 안 섭니다. 또한, 이 경우에 뭔가 모델 별, 모델성능 별, 자산별에 다 agnositic하니까 더 좋은 지표 설계일지 아니면 너무 주제를 벌려서 초점화가 안된 것으로 보일지 궁금합니다.

6-4) 라이팅

일단 시험이 끝나고 제가 할 수 있는 수준에서 반복적으로 개선을 한 결과 어느 정도의 효과는 입증했다고 생각이 드는데, 교수님께서 판단하시기에 라이팅이 들어갈 수 있는 수준인지 아니면 엄밀성을 떠나서 연구 성과 자체에 보완이 더 필요해 보이는지 궁금합니다.